LABORATORIO 01

Modelado OLTP a OLAP con PayTrack

Caso: PayTrack Colombia | Fecha: 21 de octubre de 2026 | Integrantes: Vladlen Shatunov

1) Objetivo y diagnóstico del OLTP

Se transformó el esquema transaccional normalizado (3FN) de PayTrack en un modelo estrella para analítica. El experimento utiliza 50.000 transacciones sintéticas, 500 clientes, 8 comercios y 5 métodos de pago; se midieron las tres consultas originales con EXPLAIN ANALYZE.

PLANES INICIALES EN POSTGRESQL

Consulta	Operaciones principales del OLTP	Tiempo
Q1 · Monto por categoría	Bitmap Index/Heap Scan (fecha), Hash Join con comercios, HashAggregate, Sort	11,690 ms
Q2 · Fraude por segmento	Seq Scan (50.000 transacciones), Hash Join con clientes, HashAggregate, Sort	17,370 ms
Q3 · Volumen por día/hora	Bitmap Index/Heap Scan (fecha), Sort, GroupAggregate; sin JOIN	5,951 ms

Interpretación. La 3FN mantiene clientes y comercios separados de las transacciones; Q1 y Q2 requieren un JOIN para recuperar categorías y segmentos. Q3 no requiere JOIN, pero calcula día y hora con EXTRACT() en cada fila filtrada. Si la operación real alcanzara 500.000 pagos diarios (≈182,5 millones anuales), los recorridos, las agregaciones y las uniones podrían encarecerse; el crecimiento del tiempo no puede inferirse linealmente de esta muestra.

2) Decisiones de modelado dimensional

Proceso y granularidad. El proceso es el registro de pagos. La tabla dw.fact_transactions tiene una fila por transacción individual (transaction_id), sin agregación previa. Se enlaza mediante cinco llaves foráneas a dim_date, dim_time, dim_customer, dim_merchant y dim_payment_method.

Atributos y privacidad. Fecha: calendario y día de semana; hora: hora y franja; cliente: ciudad y segmento; comercio: nombre, categoría y ciudad; pago: método y tipo (card, digital_wallet, bank_transfer). Se excluyeron nombre, correo e ingresos del cliente porque no eran necesarios para las consultas y aumentaban la exposición de datos personales.

Llaves sustitutas y SCD Tipo 2. Las surrogate keys identifican versiones independientes de los ID del OLTP. En dim_customer, city y segment pueden cambiar: valid_from, valid_to e is_current conservan el valor históricamente válido y evitan reclasificar pagos pasados. La carga inicial implementa una versión por cliente; no simula actualizaciones incrementales.

CLASIFICACIÓN DE LAS MEDIDAS

Medida	Clasificación y tratamiento
amount_cop	Aditiva: sumable por cualquiera de las cinco dimensiones.
is_fraud / is_approved	Indicadores: convertidos a 0/1 se agregan como conteos; la tasa derivada no es aditiva.
fraud_risk_score	No aditiva: no es significativo sumar puntuaciones de riesgo.

No se modeló una medida semiaditiva (p. ej., saldos que no deben sumarse entre fechas).

3) Esquema estrella y carga ELT

El modelo dimensional centraliza las métricas en fact_transactions y conserva los atributos analíticos en dimensiones. Cada dimensión se relaciona con muchas transacciones (1:N).

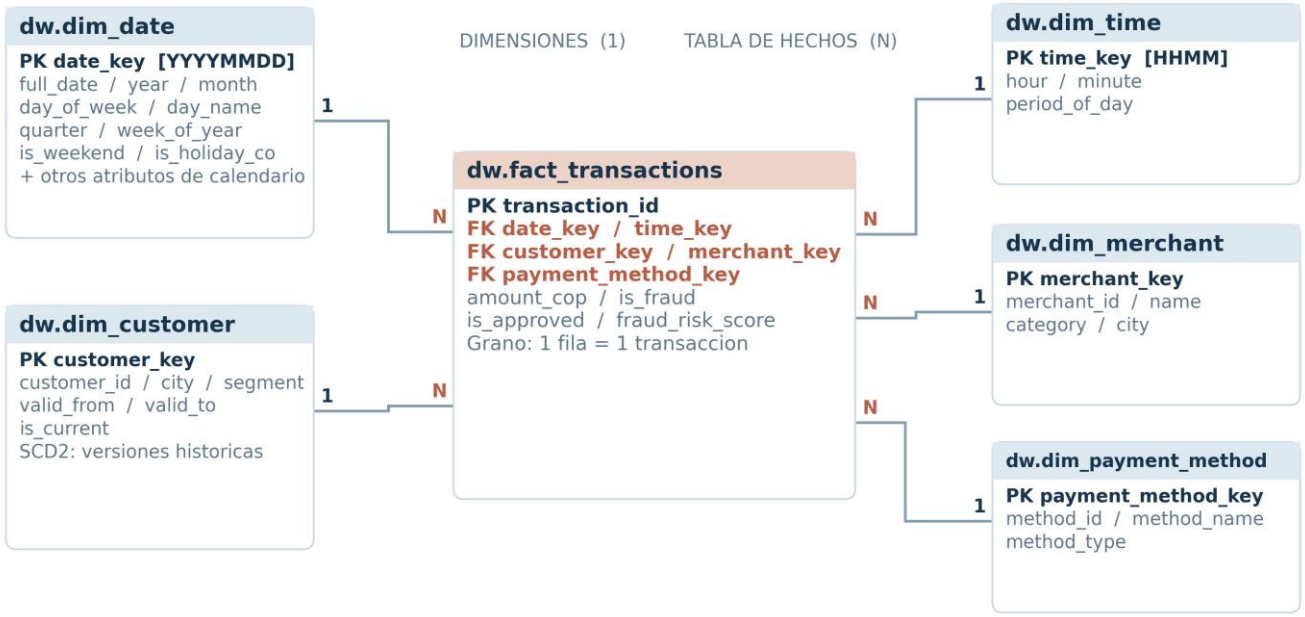


Figura 1. Vista resumida de las tablas, PK, FK y cardinalidades. El archivo drawio contiene el detalle completo.

TRANSFORMACIONES DE LA CARGA

ELT en PostgreSQL. load_star.py utiliza INSERT ... SELECT desde oltp.* hacia dw.*. Se crean 91 fechas (YYYYMMDD) y 1.440 minutos (HHMM); los métodos se clasifican con CASE y las llaves naturales se resuelven contra sus dimensiones.

Integridad histórica. La unión del cliente exige valid_from ≤ created_at y created_at < valid_to cuando existe límite. En la carga inicial valid_from = 1900-01-01, valid_to = NULL e is_current = TRUE. Un LEFT JOIN trae los eventos de fraude cuando existen; MAX(risk_score) evita multiplicar transacciones ante varios eventos.

VERIFICACIÓN DE INTEGRIDAD Y EQUIVALENCIA

Control	Resultado verificado
Carga dimensional	500 clientes · 8 comercios · 5 métodos · 50.000 hechos.
Validaciones ELT	9/9: conteos, monto total, fraude, aprobaciones y cinco referencias válidas.
Comparación de consultas	3/3: Q1 (7 filas), Q2 (3 filas), Q3 (168 filas) idénticas al OLTP.

Criterio SCD2 para Q2. No se filtra dim_customer por is_current: la tabla de hechos ya apunta a la versión histórica correcta mediante customer_key. Filtrar solo versiones vigentes excluiría transacciones vinculadas a versiones cerradas.

4) Rendimiento: OLTP frente a OLAP

Se compararon las mismas preguntas con EXPLAIN ANALYZE en PostgreSQL. Ambos modelos devolvieron resultados idénticos, pero los tiempos observados fueron menores en OLTP para las tres consultas.

Consulta	OLTP	OLAP	Observación del plan OLAP
Q1 · Categorías	11,690 ms	13,169 ms	Seq Scan sobre hechos + 2 Hash Join + HashAggregate.
Q2 · Fraude	17,370 ms	18,863 ms	Seq Scan (50.000 filas) + Hash Join con clientes.
Q3 · Día / hora	5,951 ms	9,195 ms	Seq Scan + 2 Hash Join + HashAggregate y Sort.

Lectura de los planes. Q1 y Q3 en OLTP aprovechan idx_txn_created_at para el filtro temporal; en OLAP los filtros pasan por dim_date y el optimizador decidió recorrer la tabla fact_transactions. Los JOIN adicionales de fecha/hora contribuyen al costo, aunque la estructura dimensional simplifica la formulación de análisis.

5) Experimentos con índices del modelo estrella

Se eliminaron temporalmente, mediante BEGIN / DROP INDEX / ROLLBACK, los índices de date_key, customer_key y merchant_key, individualmente y en conjunto. Ninguna prueba cambió el Seq Scan sobre fact_transactions.

Escenario OLAP	Q1	Q2	Q3
Con los tres índices	13,169	18,863	9,195
Sin idx_fact_date_key	13,178	18,058	9,107
Sin idx_fact_customer_key	12,196	19,105	10,637
Sin idx_fact_merchant_key	13,117	16,029	9,056
Sin los tres índices	14,454	16,621	10,708

Tiempos en ms; son ejecuciones individuales (no promedios). No permiten atribuir variaciones pequeñas a los índices.

Explicación. Los índices no fueron seleccionados en esta muestra de 50.000 filas. Para consultas que recorren una proporción alta de la tabla, el optimizador puede preferir un escaneo secuencial. Los índices añaden costo de almacenamiento y mantenimiento y su utilidad debe verificarse con planes y mediciones repetidas.

6) Conclusión

La transformación OLTP → OLAP conservó las 50.000 transacciones, sus totales y la equivalencia de las tres consultas (9/9 validaciones y 3/3 comparaciones). La estructura estrella facilita el análisis multidimensional y el historial SCD2, aunque no aceleró estas consultas en PostgreSQL con 50.000 filas. La elección de modelo e índices debe sustentarse en las necesidades analíticas y evidencia experimental, no en una expectativa automática de velocidad.

Fuente: repositorio del curso, laboratorio 01; datos sintéticos y planes EXPLAIN ANALYZE obtenidos durante la ejecución local del 21/10/2026.